M1 進捗（7社の再現）

作成日: 2026-10-28（同日 Step J で更新）。対象: 輸送用機器7社（`config/transport7.toml`）× 2期（2025年3月期・2026年3月期）、基準日 T=2026-09-30。 参照: `/workspace/edinet-risk-review/implementation-plan.md` §3・§4 M1・§5・§6-5・§6-6・§7。 M0 の成果は `docs/spike-findings.md`・`out/m0/`。

状況の要約: 版の選択 → 書類取得（キャッシュ優先） → 項目分割 → 対応付け → 文字差分 → SQLite 保存 → Excel・HTML・照合シートまでを、`run --offline` の一括実行で7社分通しました。**手作業 Excel は不要**です（2026-10-28 侑輝指示）。正解（gold）が必要な受け入れ条件 1〜3 と 8 は M1 の**対象外**とし、評価しません。 冪等性（条件5）は7社の実データで確認しました。`run --offline` を連続で実行し、SQLite のテーブル・Excel のセル・HTML・テキスト出力のハッシュがすべて一致し、書類取得 API の呼び出しは 0 回でした（§2-5）。 M2 には着手していません。

1. 実装したモジュール

依存は §7 の範囲（標準ライブラリ + openpyxl）。scipy はテストのオラクルとしてだけ使い、未導入なら該当テストを skip します。

区分	モジュール	内容
ingest	`ingest/doclist.py`	保存済み doclist（cache）の取り込みとマージ（M1 用の最小実装）
resolve	`resolve/versions.py`	版グループの構成と採用版の選択（§6-5、基準日 T で xbrlFlag=1 の最新版）。訂正の periodEnd は parentDocID から継承
resolve	`resolve/period.py`	当期・前期の特定、gap、前期なしの理由
segment	`segment/headings.py`, `segment/segmenter.py`	見出し候補の検出と項目分割（最下位の見出し＝項目、決定事項 D2）。番号の体系 (1)/（１）・①・１． の階層
match	`match/ngram_tfidf.py`	文字 2〜3gram の TF-IDF とコサイン類似度
match	`match/hungarian.py`, `match/lis.py`	純 Python のハンガリアン法と LIS（移動の判定）
match	`match/matcher.py`	二段方式（アンカー → 割当 → 包含で分割・統合 → 新設・削除 → 移動）。閾値は `config/thresholds.toml`（version=`m1-initial`）
diff	`diff/chardiff.py`, `diff/minor.py`, `diff/sentences.py`	文字差分、軽微な変更の判定（D4）、文の分割と対応付け
report	`report/excel.py`, `report/html.py`, `report/reconcile.py`	会社別の差分 Excel（概要・会社別・照合・出典の各シート）、全文差分 HTML、照合シート
store	`store/schema.sql`, `store/migrate.py`, `store/db.py`	SQLite スキーマ（§5）、前進のみのマイグレーション（`PRAGMA user_version`）、WAL・外部キー・upsert
net	`net/http.py`, `net/edinet_api.py`	EDINET API v2 クライアント（標準ライブラリのみ）。API キーはログ・出力・キャッシュに出さない
CLI	`m1_resolve.py`, `m1_segment.py`, `m1_match.py`, `m1_compare.py`, `m1_report.py`, `m1_run.py`	`python -m edinet_risk {m1_resolve, m1_segment, m1_match, compare, report, run, init-db}`。`compare --db` は SQLite にも保存（Step H）。`run` は一括実行で、`--offline` 付きならネットワークを禁止（Step I）
tools	`tools/gold_import.py`	手作業 Excel → 正解 JSON。**インタフェースとスタブのみ**。手作業 Excel は不要になったため、M1 では使いません（`--gold` は任意の引数として残しています）

2. 7社の結果（out/m1）

2-1. 版選択・前期特定（`out/m1/resolve_transport7.md`）

保存済み doclist 395日分（99,525件）から選択しました。docID は手で固定していません。 7社とも、当期は 2026年3月期の原本です。前期は 2025年3月期で gap=1、flags はありません。 SUBARU の前期だけは訂正版 **S100YF9D**（原本 S100W1AE）を採用しました（§3 を参照）。

2-2. 項目分割（`out/m1/segment_summary.md`、`seg-1`）

会社	2025年3月期 項目数	2026年3月期 項目数	番号の体系
トヨタ自動車	16	16	paren_num > circled
本田技研工業	16	16	paren_num > circled
日産自動車	24	24	num_dot > paren_num
SUBARU	20	23	paren_num → paren_num > circled（当期に体系が変わった）
マツダ	17	17	paren_num
三菱自動車工業	18	18	paren_num > circled
スズキ	20	20	paren_num > circled

14件すべてが分割=normal です。照合シートの「全文一致」（抽出本文 → 分割 → 差分表示の間で文字が欠けていないこと）も 14/14 で ○ でした。
要確認（自動検出）:

- 本田技研工業: 子を持つ見出しに自身の本文があります（「(1) 地政学的リスク」に 531字）。この本文は親の導入文として保持し、項目には含めていません。 - SUBARU 2025年3月期: 前文が 2,070字と長いです。番号なしの見出しの下にある本文が、前文に入っている可能性があります。 - SUBARU 2026年3月期: 「(4) 主要な事業等のリスク」に、導入文 179字があります。

2-3. 対応付け（`out/m1/match_summary.md`、`match-1`、当期 × 前期）

会社	当期/前期項目	same	modified	retitled	moved	added	要確認	番号変更
トヨタ自動車	16/16	9	7	0	0	0	0	0
本田技研工業	16/16	7	8	0	1	0	0	5
日産自動車	24/24	12	12	0	0	0	0	0
SUBARU	23/20	0	20	0	0	3	1	0
マツダ	17/17	10	6	1	0	0	0	0
三菱自動車工業	18/18	13	5	0	0	0	2	0
スズキ	20/20	15	5	0	0	0	0	0
計	134/131	66	63	1	1	3	3	5

merged・split・deleted は 0件でした。段階の内訳は アンカー 126／割当 5／包含 0 です。
要確認になったのは次の3件です。いずれも見出しは同一で、本文類似度が低いものです。

- SUBARU「③金融市場の変動」（S=0.475） - 三菱自動車工業「（１）市場環境変化の影響」（S=0.430） - 三菱自動車工業「①営業戦略…」（S=0.405）

本田技研工業の「市場環境変化リスク」は (9)→(4) に移ったため moved と判定しました。マツダの「(7) 情報技術への依存」は retitled です。
SUBARU では、当期に新設された冒頭のリスクマネジメント3項目が added になりました。

2-4. 差分・帳票（最新は `out/m1/run_20261028T130444-c58e/`）

`compare.json` の各バージョン: compare-1 / seg-1 / match-1 / diff-1 / minor-1。閾値の fingerprint は `d3902d46d8d3c146` です。
ペアごとの変更判定（changed / minor / none）と変更箇所数:

会社	changed	minor	none	変更箇所
トヨタ自動車	6	1	9	14
本田技研工業	5	4	7	32
日産自動車	12	0	12	44
SUBARU	23	0	0	223
マツダ	7	0	10	19
三菱自動車工業	5	0	13	19
スズキ	5	0	15	11

minor はすべて番号だけの変更です。

帳票:

- `risk_diff_transport7.xlsx`: 概要・会社別7枚・照合・出典の各シートがあります。1セルの最大は 1,787字で、32,767字以内です。スコア・ラベル・段階は別の列に出しています。 - `html/`: 会社別の全文差分7ファイルと index.html です。 - `reconcile.csv` / `reconcile.md`: 照合シートです。「全文一致」は 14/14 で ○ です。「手作業」の列は空で、判定は「対象外」です。

2-5. SQLite 保存（Step H）と `run --offline`・冪等性（Step I）

SQLite（`out/m1/m1.sqlite`、スキーマ user_version=1）の件数（最新の run 時点）:

テーブル	件数	内容
doclist_raw	99,525	保存済み doclist 395日分
documents	99,020	docID 単位
filing_selection	14（run ごと）	7社×2期の採用版。過去の resolve・run の分を含めた累計は 112 行
extracts	14	7社×2期の抽出本文。cache の type=1 ZIP から再抽出した本文と一致（警告なし）
items	316	seg-1 の見出しノードすべて（項目＝葉 265＝当期 134＋前期 131、残りは親の見出し）。分割はすべて normal
matches	134	当期×前期の対応ペア（match-1）
sentence_changes	362	文単位の変更。根拠ID（evidence_id）から抽出本文の該当箇所を復元できることをテストで確認
runs	12	resolve 4・compare 1・run 7
api_calls・fetches	0	14件の ZIP はすべて cache 済みのため、取得なし
code_aggregation・edinet_codes・successor_map・metrics	0	M1 では使いません（M2 以降）

`python -m edinet_risk run --offline`: resolve → fetch → compare → report を1つの run_id で実行し、`out/m1/run_{run_id}/` に resolve・compare.json・帳票・`fingerprint.json` を出力します。 `--offline` のときはネットワーク接続を禁止します（接続しようとすると `NetworkForbidden`）。cache に無い ZIP は取得せず、missing として報告します。7社では毎回 `fetch: cached=14 fetched=0 missing=0`、`api_calls: documents=0 documents.json=0（network calls=0）` でした。

冪等性（M1-5）: `fingerprint.json` で、(a) テーブルごとの行ハッシュ（run_id の列を除く。runs・api_calls・metrics は対象外）、(b) Excel のセル値と書式のスナップショット、(c) HTML、(d) テキスト出力（run_id はマスク）を比較します。xlsx のバイナリは比較しません。

run_id	tables	excel	html	前の run との比較
20261028T125952-d7cf ほか計4回	42a6d0f8faeb	d76eef9f433b	ab588781a083	4回とも一致
20261028T130422-6e3f	42a6d0f8faeb	b15be09bebd4	ab588781a083	excel・reconcile のみ相違（照合の判定ラベルを「未受領」→「対象外」に変えたため。意図した変更）
20261028T130430-a8fd	同上	同上	同上	一致（tables・excel・html・files）
20261028T130444-c58e	同上	同上	同上	一致（tables・excel・html・files）。**最新**

ラベルを変えた前後で、テーブルと HTML のハッシュは変わっていません。同じ確認は `tests/test_run.py::test_transport7_run_offline_twice`（7社、一時ディレクトリで2回実行）でも自動で行っています。

`out/m1/` には、ラベル変更前の run ディレクトリ（`run_20261028T121739`、`run_20261028T125445`、`run_20261028T1259*`〜`T130234*`）も残しています。これらの照合シートの「未受領」は、現在の「対象外」と同じ意味です（`out/m1/README.md`）。

3. SUBARU 訂正報告書の結論（`out/m0/subaru_amendment_note.md`）

risk_changed_by_correction = False です（SUBARU 2025年3月期）。

版グループは S100W1AE（原本）と S100YF9D（訂正、2026-06-22付け）です。§6-5 の規則に従い、訂正 S100YF9D を採用しました（version_kind=correction）。
訂正 ZIP は全文を再提出したインライン XBRL です。BusinessRisksTextBlock は1件で、原本と完全に一致しました（12,133字、正規化後 11,976字）。
訂正の理由は「セグメント情報」の注記と監査報告書の記載誤りで、事業等のリスクは訂正の対象外です。
全文の TextBlock があるため `correction_partial` は付きません。
S100YF9D の type=1 ZIP は API で1回だけ取得し、`cache/docs/` に保存しました。それ以降はオフラインで処理しています。
この件は「訂正あり・本文不変」の回帰ケースとして使えます。

4. 受け入れ条件の状況と残課題

受け入れ条件（§4 M1）	状況
1. 照合 14/14・境界F1 ≥ 0.95	**対象外**（手作業 Excel 不要の指示による）。代わりに自動の「全文一致」14/14 と、分割の lossless（前文＋全項目＝抽出本文）を確認済みです
2. 適合率 ≥ 0.95・再現率 ≥ 0.90・混同行列	**対象外**（正解ペアを作らないため）。`match_summary.md` はラベル分布の確認用です
3. 変更あり/なしの100%一致・色付け範囲F1	**対象外**（同上）
4. Excel のセル上限・全文 HTML・出典シート	達成（最大 1,787字、HTML あり、出典シートあり）
5. 冪等性	**達成**。7社の実データで、テーブル・Excel・HTML・テキストのハッシュが一致し、2回目以降の書類取得 API は 0 回でした（§2-5）
6. `--offline` での再現	**達成**。`run --offline` でネットワークを禁止した状態で7社を再現しました（§2-5）
7. スコア・ラベル・段階を別列に出すこと	達成
8. `tests/golden/seven/` の固定と CI 回帰	**対象外**（正解 JSON を作らないため）。7社の回帰は、cache がある環境では `test_transport7_into_sqlite`・`test_transport7_run_offline_twice` で走ります（cache が無い環境では skip）

残課題（M1 の受け入れを止めるものではありません）：

要確認の項目は、まだ人が見ていません。分割では SUBARU 2025年3月期の前文 2,070字など（§2-2）、対応付けでは本文類似度が低い3件（§2-3）です。
`tools/gold_import.py` はスタブのままです。M1 では使いません。
ハンガリアン法の scipy オラクル比較は、scipy が未導入のため skip しています。
M0 からの持ち越し: 社内PCでの実機確認（M0 条件1・ブロッカー B5）と、702001 の実例 docID（M0 条件8）。詳細は `docs/spike-findings.md` §6 にあります。

5. 次のアクション

M2 は未着手です。

1. M1 の受け入れを判断します（条件 4〜7 は達成、1〜3・8 は対象外）。 2. 必要に応じて、要確認の項目（SUBARU 2025年3月期の前文、類似度が低い3件）を人が確認します。結果によっては seg-2 / thresholds の版を上げます（閾値の本格的な調整は M2 の層別サンプルで行います）。 3. M0 の持ち越し（社内PCでの実機確認、702001 の実例）を進めます。 4. 受け入れが決まったら M2 に進みます。

6. テスト結果（最終）

```
.venv/bin/pytest -q -m "not live"
229 passed, 1 skipped, 2 deselected in 14.91s
```

前回（Step G 時点）の 212 passed から、Step H の `tests/test_compare_db.py`（8件）と Step I の `tests/test_run.py`（9件）で 17件増えました。
skipped 1: `tests/test_match.py:123`。scipy が未導入のため、ハンガリアン法のオラクル比較を skip しています。
deselected 2: live テストです（ネットワークを使うため除外）。