M0 スパイク調査結果（spike-findings）

対象: implementation-plan.md §4 M0 および §10-3「M0で確かめる未確認事項」。 実施環境: 開発機（Linux、venv の CPython 3.12）。**社内PC・embeddable Python では未実施**（§6 参照）。 API 呼び出し: 計 456 回（type=2 書類一覧 395、type=1 XBRL 26、type=5 CSV 35）、すべて HTTP 200、429 は 0 回。 呼び出し間隔は 1 秒以上（自主制限）、応答は cache/ に保存し再実行時は再取得しない。ログ上の URL は APIキーをマスク済み。

根拠データ（すべて out/m0/）:

内容	ファイル
CSV 切り詰め条件	truncation_note.md, truncation_facts.csv, csv_xbrl_compare.md（マツダ単独）
様式コードのクロス集計	formcode_crosstab.md, formcode_crosstab.csv, formcode_watch_hits.json, doclist_scan_failures.json
7社×2期の取得結果	transport7_summary.md, <docID>_business_risks.txt, <docID>_meta.json
本文の構造（表・箇条書き・画像）	structure_note.md

---

1. CSV（type=5）の 30,000 字切り詰め【受け入れ条件 7】

結論: 条件を特定できた。CSV は本文のソースに使わない（計画どおり type=1 XBRL を正とする）。

- 比較対象: 長文の有報 11 件（日本郵政、かんぽ生命、SBI HD、NTT、ゆうちょ銀行、野村HD、SBG、ソニーG、りそなHD、オリックス、MS&AD）の TextBlock 569 ファクト（CSV または生 HTML が 20,000 字以上のもの）。
- 切り詰められたファクトは 13 件（BusinessRisks 3 件＋その他の TextBlock 10 件）。
- **上限は文字数で 30,000**。13 件すべてで len()＝UTF-16 単位数＝30,000 ちょうど。UTF-8 バイト数（71,546〜89,424）、 cp932 バイト数（50,774〜59,712）はばらつくため、バイト数ではない。 （サロゲートペアを含む値が無く、コードポイントと UTF-16 単位の区別は未確認）
- **数える対象はタグ除去後の CSV 値そのもの**（空白・改行、リテラルの & 等を含む）。生 HTML（数万〜数百万字）に対する上限ではない。
- **末尾に印は付かない**（「以下省略」等なし）。値は XBRL 本文の接頭辞（正規化後に 13/13 件で接頭辞一致）で、文の途中で切れる。

- 30,000 字未満は切り詰められない（未切り詰めの最大は 29,714 字）。→ **`len(CSV値) == 30000` を「切り詰め疑い」の判定条件にする**。
- CSV 値に HTML タグは残らない。画像は消え、`<前連結会計年度>` のようなタグ風の本文も消える。表のセルは空白区切りで連結される。
- BusinessRisks の切り詰め例: 日本郵政 S100YE7T（XBRL 正規化後 33,910 字 → CSV 29,893 字で切断）、かんぽ生命 S100YD29、SBI HD S100YK3R。
- 7 社×2 期では最大 14,957 字で、切り詰めは 0 件（マツダの詳細比較は `csv_xbrl_compare.md`。正規化後に CSV と XBRL が完全一致）。

その他の未確認事項（§10-3）

事項	結果
`BusinessRisksTextBlock` の contextRef	`FilingDateInstant`（XBRL・CSV とも。取得した全書類で同じ）
`.xbrl` が PublicDoc に常にあるか	取得した type=1 の全書類（7社×2期＋比較用 11 件）で `XBRL/PublicDoc/*.xbrl` があった。iXBRL へのフォールバックは未実装のまま（M1 で無い書類が出たらエラーで止まる）
要素名の完全一致	`MaterialMattersRelatingToGoingConcernEtcBusinessRisksTextBlock` を拾わず、14/14 件でちょうど 1 件に一致
レート制限	1 秒間隔で 456 回、429 は 0 回。数値は公式に無いため自主制限を継続し、429 の回数を監視する
訂正の訂正の parentDocID	**未確認**（実例なし）。SUBARU の訂正 S100YF9D の parentDocID は原本 S100W1AE（1 回目の訂正）。M2 までに実例で確認する

---

2. 様式コード（formCode）のクロス集計【受け入れ条件 8】

走査窓: 提出日 2025-06-01〜2026-06-30（395 日、取得失敗 0 日）、書類 99,525 件、組合せ 144 種。 公式の様式コード表（`ref/ese140327/ESE140327.xlsx`、(府令,様式) 413 件）と照合し、**メタデータ消去（取下げ等）を除く全組合せが表と整合**した。

formCode	公式の意味（府令 010）	窓内の件数と実例
030000	有価証券報告書	120/010 6,626 件（例 S100VW2P HOYA）、120/020 51 件（外国政府等、例 S100VWQ0 アルゼンチン共和国）、**350/060 1,209 件**
030001	訂正有価証券報告書	130/010 838 件（例 S100VUX5 識学、S100YF9D SUBARU）、130/020 5 件（例 S100WW0J 大韓民国）

formCode	公式の意味（府令 010）	窓内の件数と実例
702001	XBRLの修正（内国会社－有価証券報告書）。書類種別は訂正有価証券報告書	**窓内 0 件**（実例 docID なし）

- **注意: formCode 030000 は府令 060 では「大量保有報告書（特例対象株券等）」（docTypeCode 350）を指す。** 窓内に 1,209 件あり、formCode だけで絞ると有報に大量保有報告書が混入する。 **有報の絞り込みは `docTypeCode=120` かつ `ordinanceCode=010` を必ず併用する**（`config/filing_filter.toml` の現行設定どおり。条件はコードに直書きせず同ファイルから読む）。
- 府令 020（外国政府等）の 120/030000 は内国会社の有報ではないので、`ordinanceCode=010` で除外してよい。
- 生成スクリプトの修正: `formcode_crosstab.md` の「注目 formCode」で、030000 の名称を府令 010 の名称（有価証券報告書）だけで表示しており、 350/060 の分も有報に見える誤表記になっていた。`m0_scan.write_report` を (府令, 様式) ごとに公式名と実例 docID を出すよう修正し、 府令によって意味が変わる場合は注意書きを出すようにした（テスト `test_watch_formcode_labelled_per_ordinance` を追加）。 `formcode_crosstab.md` はキャッシュから再生成済み（API 呼び出し 0 回）。

---

3. 輸送用機器 7 社×2 期の取得結果【受け入れ条件 2・4・6】

対象: トヨタ、ホンダ、日産、SUBARU、マツダ、三菱自、スズキ × 2025年3月期・2026年3月期（`config/transport7.toml`、edinetCode で照合）。 絞り込み: docTypeCode=120, ordinanceCode=010, formCode=030000, xbrlFlag=1, 取下げなし。

- **14/14 件で取得・抽出に成功**。各社・各期で書類は一意に 1 件。本文は 5,647〜14,957 字（30,000 字超は 0 件）。
- 走査窓: 提出日 6/10〜6/30。**トヨタの 2026 年提出は 2026-06-10 15:33 で、窓の初日だった**。 他業種・全社に広げるときは窓を 6 月初めまで広げる（全社用の書類一覧キャッシュは 2025-06-01〜2026-06-30 を取得済み）。
- **SUBARU の訂正報告書 S100YF9D**（030001、2026-06-22 10:36 提出、第 94 期＝2025年3月期、parentDocID=S100W1AE）がある。 表の SUBARU 2025 年版は原本 S100W1AE の本文。訂正が事業等のリスクに及ぶかは未確認で、M1 の版選択（訂正があれば訂正後を使う）で判断する。 ほかに三菱自の訂正 S100VZM0（parentDocID=S100TPY6、前々期の書類）が窓内にある。
- 本文の構造（`structure_note.md`）:
- 表題行「３ 【事業等のリスク】」は全件で除去済み。

- `<table>` は SUBARU の両期のみ（気候変動リスク・機会の表 2 個、11 行）。表は 1 行＝1 テキスト行（セルは TAB 区切り）で残る。 ただし `rowspan` の結合セルがあると列が左にずれる。
- `<ul>`/`<ol>` は 0/14。箇条書きは `<p>` 内の行頭記号（日産・マツダ「・」、SUBARU「※」）で、行単位で残る。
- リスク項目の見出しは全社で (1)/① 等の番号付き段落（17〜28 行）。M1 の項目分割の手がかりになる。
- `<img>` は SUBARU・スズキの両期に各 1 個で **alt が空**。現行の `html_to_text` は alt があるときだけ `[画像: alt]` を出すため、跡が残らない。
- SUBARU 2025 年版は原文 HTML の改行に由来する空白が和文中に入る（「浸水によ る」）。比較時の正規化で吸収する。

---

4. `html_to_text` の入れ子の表の修正

- 不具合: セルの中にある `<table>`（入れ子の表）の内容が丸ごと落ちていた。CSV との比較（切り詰め調査）で、 「役員の状況」などで XBRL テキストが CSV より短くなる箇所から発見した。
- 修正: セル内で開いた表は外側のセルに平坦化する（内側のセルは空白区切りで外側のセルの文字列に入れ、外側の行は 1 行のまま保つ）。
- テスト: `tests/test_extract.py::test_nested_table_inside_cell_is_flattened_not_dropped`。
- 7 社×2 期の BusinessRisks には入れ子の表が無く、影響は無い。

---

5. M0 受け入れ条件の達成状況

#	条件	状況
1	社内PCの embeddable Python から、`verify=False` なしで書類一覧・書類取得 API が成功し、TLS 検証の成功がログに残る	**未達**。開発機でのみ成功。社内PC・プロキシ・社内 CA（truststore）での確認とログ出力は未実施
2	ordinanceCode=010・formCode=030000 で対象書類が一意に 1 件	達成（開発機、7社×2期の 14/14）。docTypeCode=120 の併用が必須（§2）
3	応答の 3 点検査（Content-Type、ZIP、PublicDoc/*.xbrl）と、誤った docID・APIキーで HTTP 200 でもエラー検出	達成（`tests/test_client.py` の単体テスト。実応答の形は live テスト `tests/test_live.py` で確認）
4	要素名の完全一致でちょうど 1 件、GoingConcern 側を拾わない	達成（単体テスト＋14/14）
5	WizLabo 由来の手作業の本文と、正規化後に 99% 以上一致（`SequenceMatcher.ratio()`）、差	**対象外**（2026-10-28 侑輝指示: 手作業 Excel・WizLabo 本文は不要）。比較は実施しない。抽出の

#	条件	状況
	分を説明	欠落は M1 の照合シート「全文一致」14/14 で代替確認（docs/m1-progress.md）
6	表題行が除去され、表は行単位、箇条書きは行頭記号付きで残る	概ね達成。課題: rowspan による列ずれ、alt 無し画像の消失（§3）
7	未確認事項と切り詰め条件を本書に記録	達成（§1）
8	クロス集計と公式表の照合結果、030001・702001 の意味を実例 docID 付きで確定。絞り込み条件は設定ファイルから読む	**一部未達**。030001 は実例付きで確定。**702001 は公式表で意味（XBRLの修正、書類種別＝訂正有報）を確認したが、窓内 0 件で実例 docID が無い**。照合と設定ファイル読込は達成

ほかに計画 §4 M0 の作業「社内PCで embeddable Python 3.12 上でスパイクが動くか（AppLocker・SmartScreen・Mark of the Web）」も**未実施**（ブロッカー B5）。

---

6. 次のアクション

1. **社内PCでの実機確認（条件 1、B5）**: embeddable Python 3.12＋本パッケージを zip で持ち込み、`python -m edinet_risk m0_spike --filer マツダ` を実行。 AppLocker／SmartScreen／Mark of the Web で止まるか、`truststore` 経由の TLS 検証成功をログに残せるかを確認する。不可なら配布パス・ハッシュの許可を申請する。
2. ~~WizLabo 本文との 99% 一致（条件 5）~~: **対象外**（2026-10-28 侑輝指示で手作業の成果物は不要）。M1 は手作業 Excel なしで進めた（`docs/m1-progress.md`）。
3. **702001 の実例（条件 8）**: 窓を広げて（例: 2023 年以降の書類一覧）実例 docID を探す。見つからなければ「公式表で確定、実例なし」として受け入れ判断を仰ぐ。
4. **`filing_filter.toml` の M2 向け更新**: 計画 §6-1 どおり docTypeCode ∈ {120,130}、ordinanceCode=010、formCode ∈ {030000, 030001}（702001 は訂正の版として扱う）を有効化する。 いずれも ordinanceCode=010 の併用を外さない。
5. **SUBARU 訂正 S100YF9D の確認**: type=1 を取得し、事業等のリスクが訂正対象か（本文の差分）を確認する。M1 の版選択のテストケースにする。
6. **`html_to_text` の改善（M1）**: alt 無し画像に [画像] プレースホルダを出す。rowspan 展開の要否を決める。比較時の正規化に和文文字間の空白除去を入れる。
7. **走査窓**: 有報の提出日窓を 6 月初めからにする（トヨタは 6/10 提出）。
8. 訂正の訂正の parentDocID（原本か直前版か）を M2 までに実例で確認する。